Herramientas para Proyectos de Ciencia de Datos

Bloque F: Dominio de las herramientas y lenguajes esenciales para ejecutar proyectos de ciencia de datos con eficiencia y profesionalismo

Bloque F: Herramientas para Proyectos de Ciencia de Datos

Saberes Declarativos:

- Preparación del ambiente de trabajo.
- Plataformas para colaboración y control de versiones.
- Lenguajes de programación del científico de datos.

Evidencia y Ponderación:

10%

Tabla comparativa: Sobre el uso de diferentes lenguajes y arquitecturas, vinculada al Problema Prototípico.

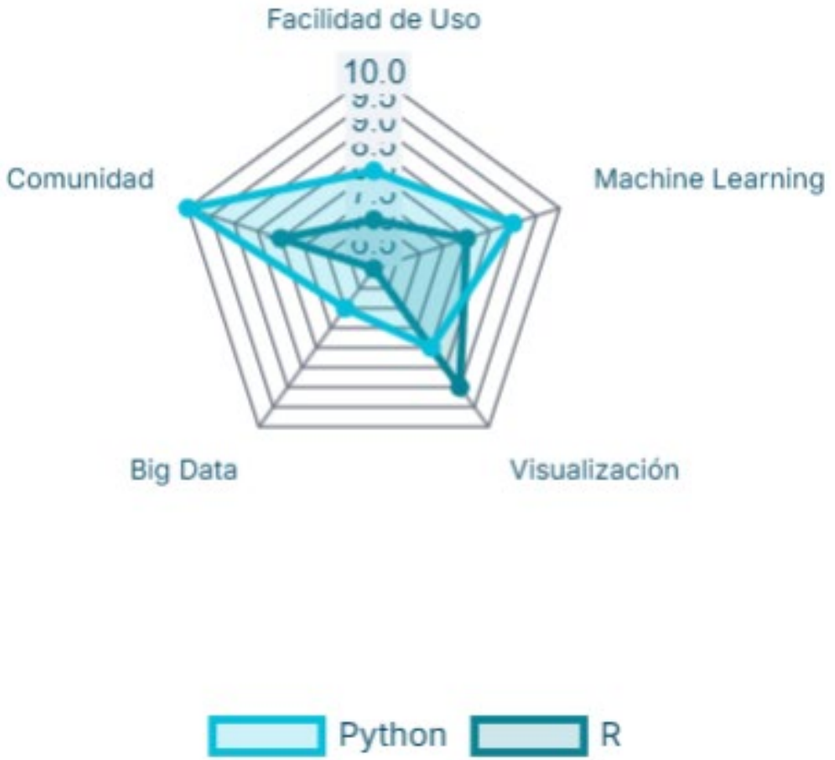

Comparación de lenguajes para ciencia de datos.

Objetivos de Aprendizaje del Bloque

Saberes Declarativos

Comprender la importancia de la preparación del ambiente de trabajo, las plataformas de colaboración como Git y GitHub, y los lenguajes de programación clave para la ciencia de datos: Python y R.

Saberes Procedimentales

Ser capaz de configurar un ambiente de trabajo profesional, utilizar sistemas de control de versiones de manera efectiva, y diferenciar las características y aplicaciones de los principales lenguajes de programación.

Durante las semanas 11 y 12, desarrollaremos las competencias técnicas fundamentales que todo científico de datos debe dominar en el entorno profesional actual.

Estructura del Bloque F

01

Preparación del Ambiente

Configuración de entornos virtuales, gestión de dependencias y mejores prácticas para un espacio de trabajo organizado

02

Colaboración y Control de Versiones

Dominio de Git y GitHub para trabajo en equipo, seguimiento de cambios y gestión profesional de proyectos

03

Lenguajes de Programación

Python y R como herramientas fundamentales, sus ecosistemas, fortalezas y aplicaciones específicas en ciencia de datos

¿Por qué es Fundamental la Preparación del Ambiente?

Un ambiente de trabajo bien configurado es la base de la productividad en ciencia de datos.

La correcta preparación evita conflictos de dependencias, facilita la reproducibilidad de análisis y permite un desarrollo más eficiente.

¿Por qué es Fundamental la Preparación del Ambiente?

Los entornos virtuales aíslan los proyectos, asegurando que cada uno tenga las versiones exactas de las librerías que necesita sin interferir con otros trabajos.

Entornos Virtuales: Aislamiento y Control

Aislamiento de Proyectos

Cada proyecto tiene su propio conjunto de dependencias sin conflictos. Un proyecto puede usar Pandas 1.3 mientras otro usa Pandas 2.0 sin problemas.

Reproducibilidad Garantizada

Los entornos virtuales permiten documentar y recrear exactamente las mismas condiciones de desarrollo, fundamental para compartir código y resultados.

Gestión Eficiente

Facilita la instalación, actualización y eliminación de paquetes sin afectar el sistema operativo o otros proyectos en desarrollo.

Herramientas para Gestión de Ambientes

Conda

Un gestor de paquetes y entornos multiplataforma que maneja tanto paquetes de Python como binarios de otros lenguajes. Ideal para proyectos de ciencia de datos con dependencias complejas.

Ventajas clave:

- Gestión simplificada de dependencias complejas
- Compatible con múltiples lenguajes
- Excelente para bibliotecas científicas
- Integración con Anaconda

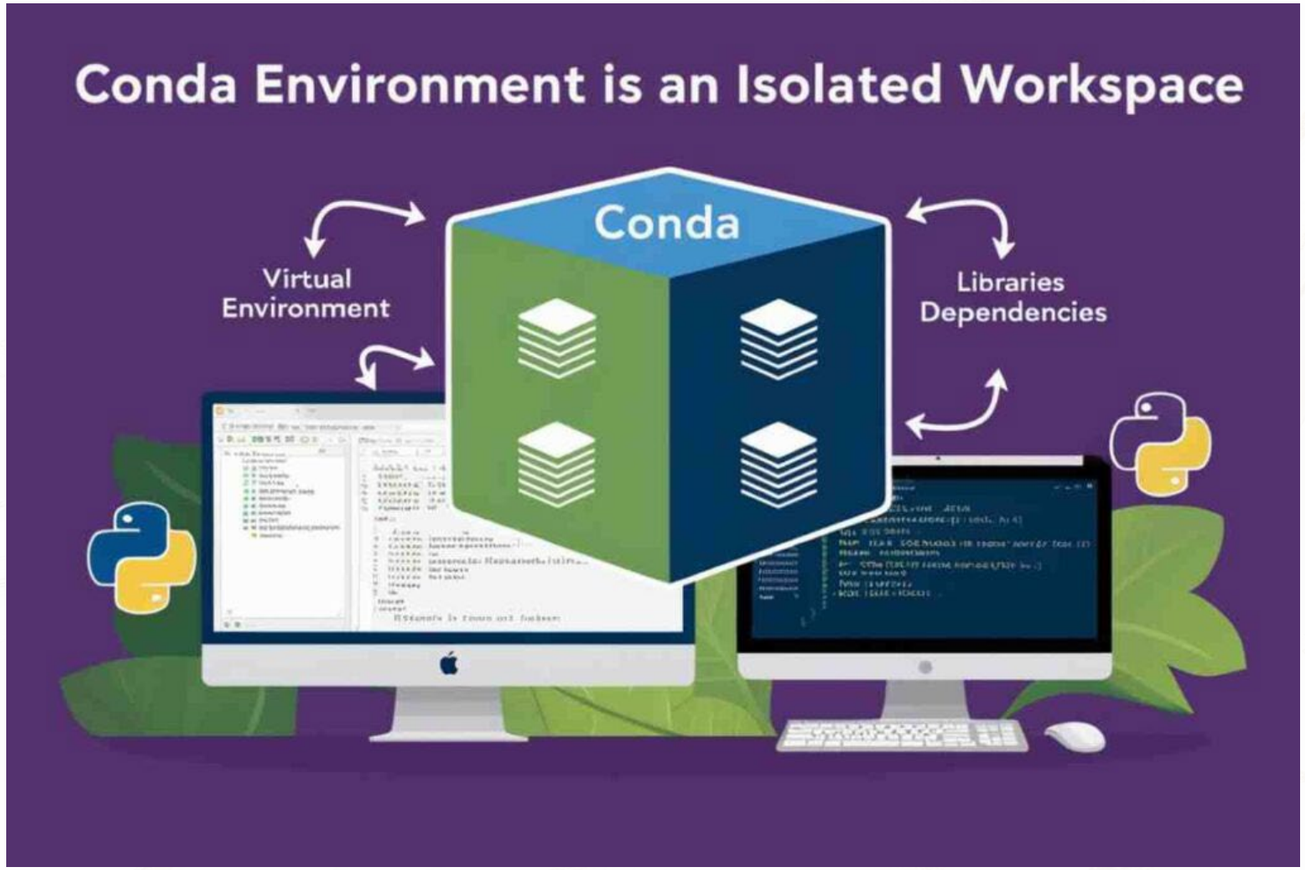

Herramientas para Gestión de Ambientes

Instalación

[Installing conda — conda 25.9.2.dev61 documentation]

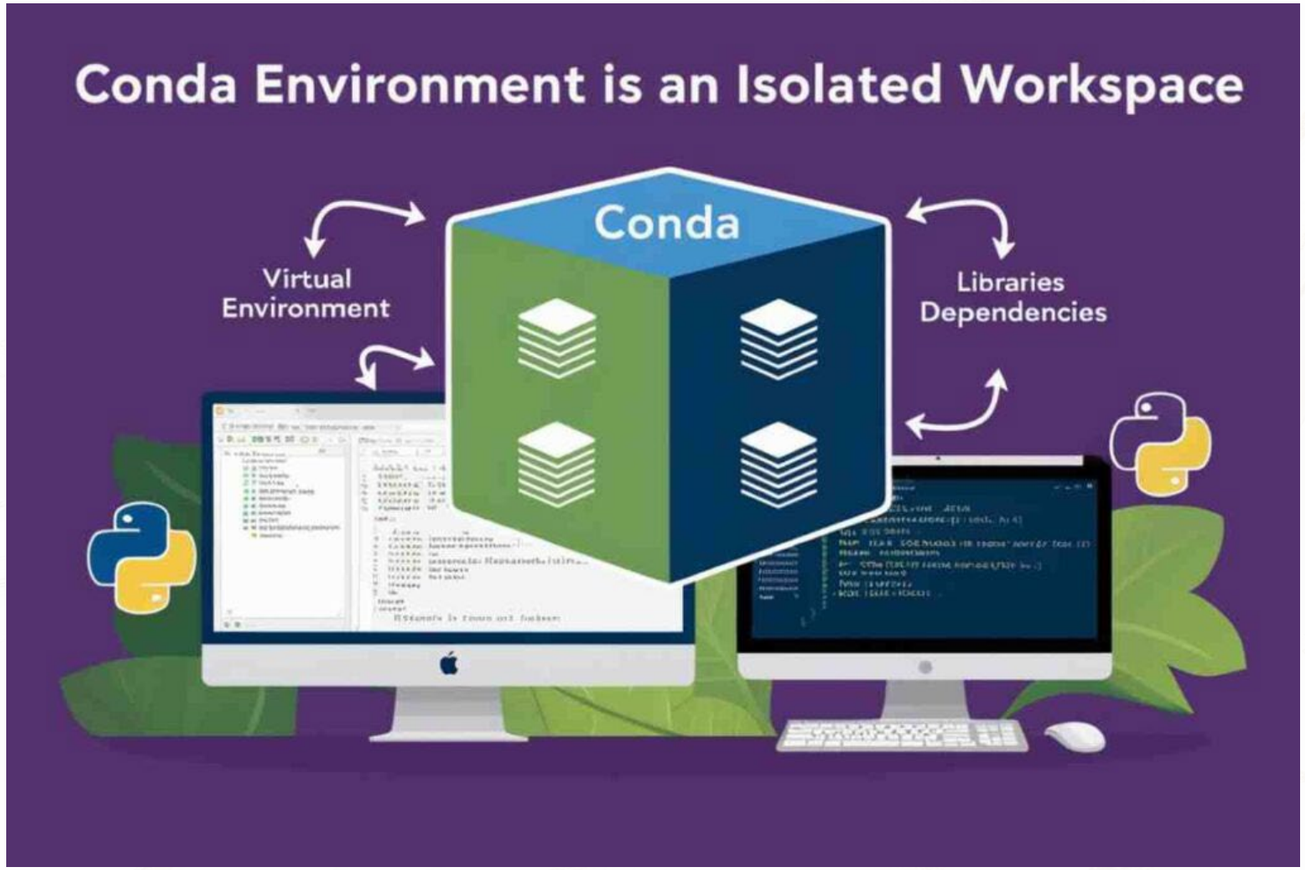

Navigation

- User guide
  - Getting started with conda
  - Installing conda
    - Installing on Windows
    - Installing on macOS
    - Installing on Linux
    - RPM and Debian Repositories for Miniconda
  - Tasks
  - Configuration
  - Concepts
  - Troubleshooting
  - Cheatsheet
- Configuration
- Commands
- Release notes
- Glossary
- Developer guide

User guide > Installing conda

Installing conda

To install conda, you must first pick the right installer for you. The following are the most popular installers currently available:

Miniconda

Miniconda is a minimal installer provided by Anaconda. Use this installer if you want to install most packages yourself.

Anaconda Distribution

Anaconda Distribution is a full featured installer that comes with a suite of packages for data science, as well as Anaconda Navigator, a GUI application for working with conda environments.

Miniforge

Miniforge is an installer maintained by the conda-forge community that comes preconfigured for use with the conda-forge channel. To learn more about conda-forge, visit their website.

Note

Miniconda and Anaconda Distribution come preconfigured to use the Anaconda

On this page

System requirements
Regular installation
Installing in silent mode
Cryptographic hash verification

Edit on GitHub

Show Source

I A UNIR

Home | Cloud: Data Science and Python Tools from Anaconda

https://anaconda.com/app/

I A UNIR | laureate cursos | octorado | OLIVARES ROBLES... | Exámenes online | iti | Exámenes online | BANNER UNITEC | Hacienda cfdi | Code.org | Turnitin | calendario | Otros favoritos

ANACONDA.

Search Anaconda packages, collections, documentation, and more! CMD + K

Upgrade | MG

Unified Search is here! Find packages, docs, collections, and community content—all from one search bar. Learn more ×

+ Create

- Dashboard
- Resources
  - Getting Started
  - My Learning
  - Documentation
- Forum
- Support

Welcome Back, Monica Guadalupe!

Launch a Notebook
Get started with a Jupyter Notebook

Take a Course
Build data science and AI skills

Join the Community
Engage with others in our community

Explore Anaconda

Notebooks | Learning | Forum | Docs | AI Navigator

Herramientas para Gestión de Ambientes

venv

La herramienta nativa de Python para crear entornos virtuales. Ligera, rápida y perfecta para proyectos que solo requieren paquetes de Python.

Ventajas clave:

- Incluida en Python 3.3+
- Sin instalaciones adicionales
- Rápida y ligera
- Ideal para proyectos simples

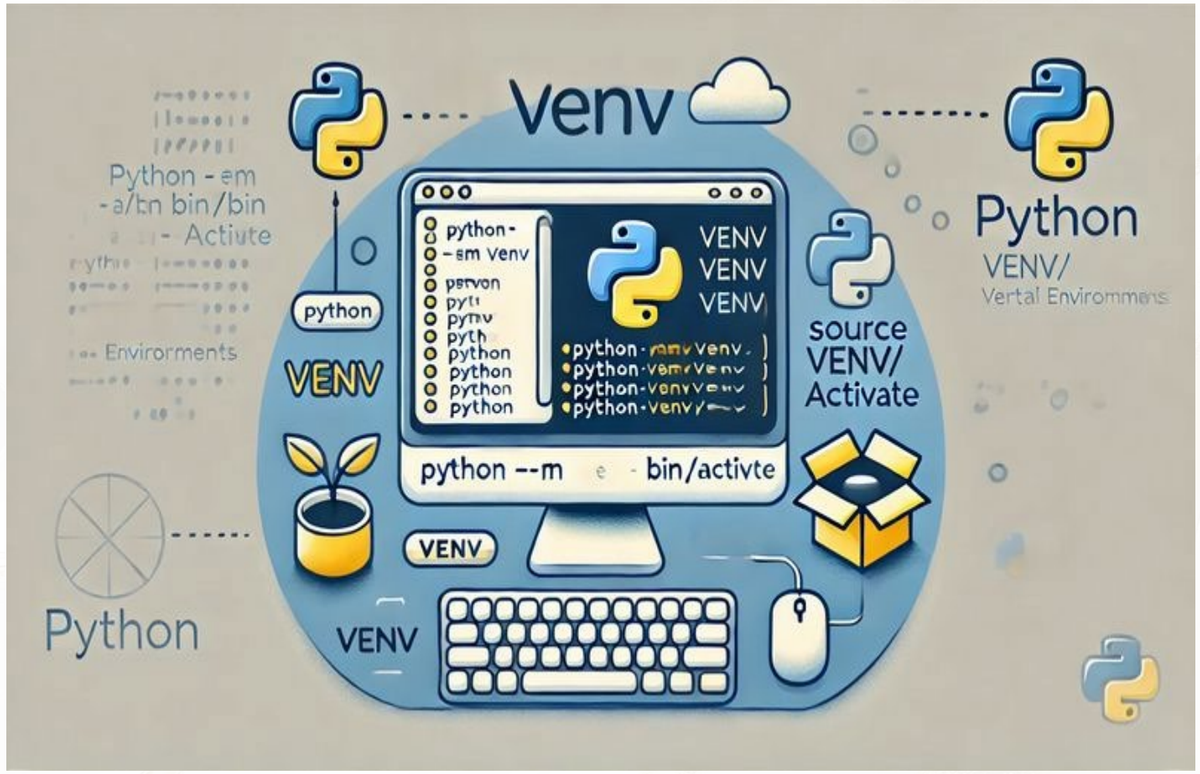

Herramientas para Gestión de Ambientes

venv

La herramienta nativa de Python para crear entornos virtuales. Ligera, rápida y perfecta para proyectos que solo requieren paquetes de Python.

Ventajas clave:

- Incluida en Python 3.3+
- Sin instalaciones adicionales
- Rápida y ligera
- Ideal para proyectos simples

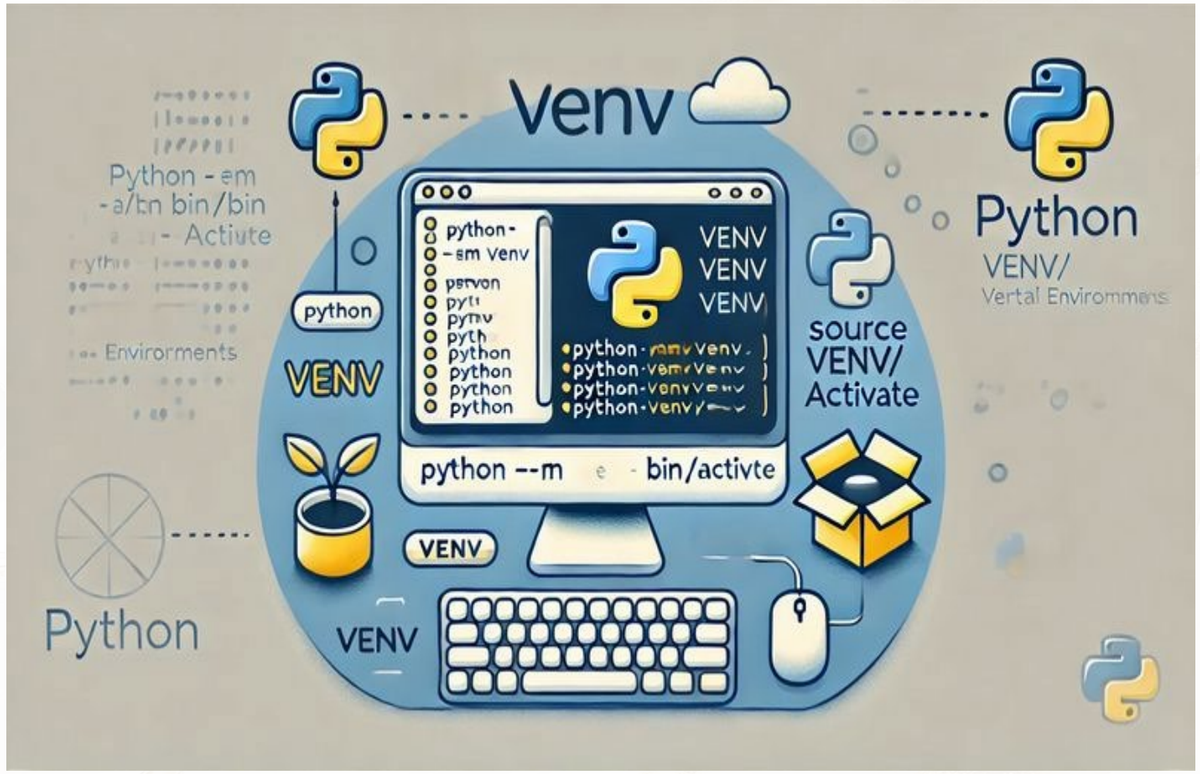

Pasos para Configurar tu Ambiente

Instalación de Python

Descarga e instala la versión más reciente de Python desde python.org o instala Anaconda para un paquete completo con herramientas de ciencia de datos.

Creación del Entorno Virtual

Usa `python -m venv nombre_entorno` o `conda create -n nombre_entorno python=3.9` para crear un entorno aislado para tu proyecto.

Activación del Entorno

Activa el entorno con `source nombre_entorno/bin/activate` (Linux/Mac) o `nombre_entorno\Scripts\activate` (Windows).

Instalación de Paquetes

Instala las librerías necesarias con `pip install pandas numpy scikit-learn` o `conda install pandas numpy scikit-learn`.

Gestión de Dependencias: Requirements.txt

El archivo `requirements.txt` documenta todas las librerías y versiones específicas que tu proyecto necesita. Esto es fundamental para la reproducibilidad.

Para generar el archivo:

```
pip freeze > requirements.txt
```

Para instalar desde el archivo:

```
pip install -r requirements.txt
```

Esta práctica garantiza que cualquier persona pueda recrear exactamente tu ambiente de desarrollo, facilitando la colaboración y el despliegue de proyectos.

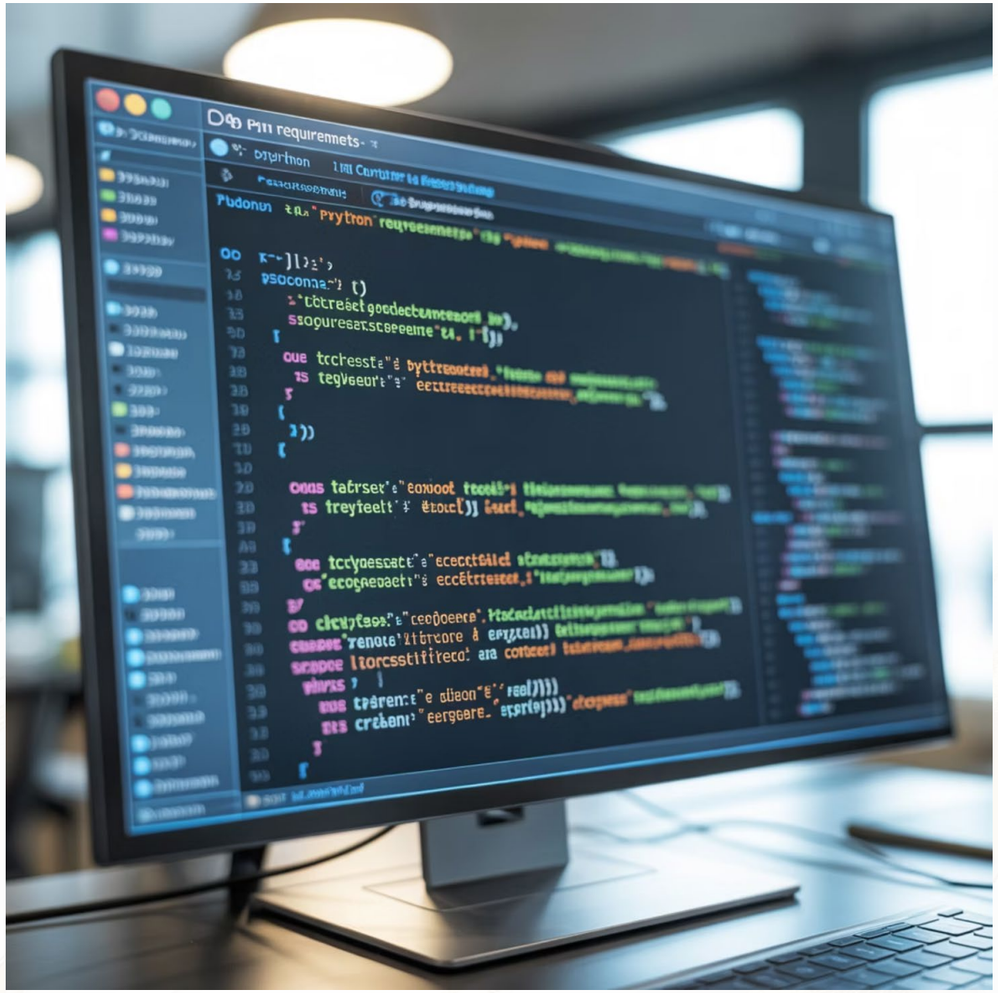

Mejores Prácticas de Configuración

Un entorno por proyecto

Nunca compartas entornos entre proyectos. Cada proyecto debe tener su propio ambiente virtual aislado.

Nombres descriptivos

Usa nombres claros para tus entornos que indiquen el proyecto o propósito: `proyecto_ventas_2024` en lugar de `env1`.

Documentación actualizada

Mantén tu `requirements.txt` o `environment.yml` actualizado cada vez que agregues o actualices paquetes.

Control de versiones

Incluye archivos de dependencias en tu repositorio Git, pero **nunca** incluyas la carpeta del entorno virtual en sí.

Siguiente sesión

Git: Control de Versiones Distribuido

Git es el sistema de control de versiones más utilizado en el mundo del desarrollo de software y la ciencia de datos. Permite rastrear cambios en el código, colaborar con otros desarrolladores y mantener un historial completo del proyecto.

A diferencia de sistemas centralizados, Git es **distribuido**: cada desarrollador tiene una copia completa del repositorio, lo que permite trabajar offline y facilita la colaboración sin depender de un servidor central.

Conceptos Fundamentales de Git

Repositorio

Un repositorio (o repo) es el contenedor del proyecto que almacena todos los archivos y el historial completo de cambios. Puede ser local o remoto.

Commit

Una instantánea de los cambios en el proyecto. Cada commit tiene un mensaje descriptivo y un identificador único que permite rastrear la evolución del código.

Branch (Rama)

Una línea independiente de desarrollo. Permite trabajar en nuevas características sin afectar la rama principal, facilitando la experimentación segura.

Merge

El proceso de integrar cambios de una rama a otra. Combina el trabajo de diferentes desarrolladores o características en una sola versión unificada.

Flujo de Trabajo Básico con Git

Modificar

Realizas cambios en los archivos de tu proyecto: código, documentación, datos, etc.

Agregar (Stage)

Seleccionas qué cambios quieres incluir en el próximo commit con `git add`.

Confirmar (Commit)

Guardas los cambios en el historial con un mensaje descriptivo usando `git commit`.

Enviar (Push)

Subes los commits al repositorio remoto con `git push` para compartir tu trabajo.

Este ciclo se repite continuamente durante el desarrollo del proyecto, creando un historial detallado y rastreable de todos los cambios realizados.

Comandos Git Esenciales

Configuración Inicial

```
git config --global user.name "Tu Nombre"git config --global user.email "tu@email.com"git init
```

Colaboración

```
git clone url_repositoriogit pullgit push origin main
```

Trabajo Diario

```
git statusgit add archivo.pygit add .git commit -m "Mensaje descriptivo"
```

Ramas

```
git branch nombre_ramagit checkout nombre_ramagit merge nombre_rama
```

Tip profesional: Escribe mensajes de commit claros y descriptivos. En lugar de "arreglos", usa "Corrige validación de datos en función process_data()".

GitHub: Colaboración en la Nube

GitHub es una plataforma web que aloja repositorios Git en la nube, facilitando la colaboración entre equipos distribuidos geográficamente. Va más allá del simple almacenamiento: ofrece herramientas para revisión de código, gestión de proyectos, automatización y documentación.

Con más de 100 millones de usuarios, GitHub se ha convertido en el estándar de facto para el desarrollo colaborativo, siendo esencial en el portafolio profesional de cualquier científico de datos.

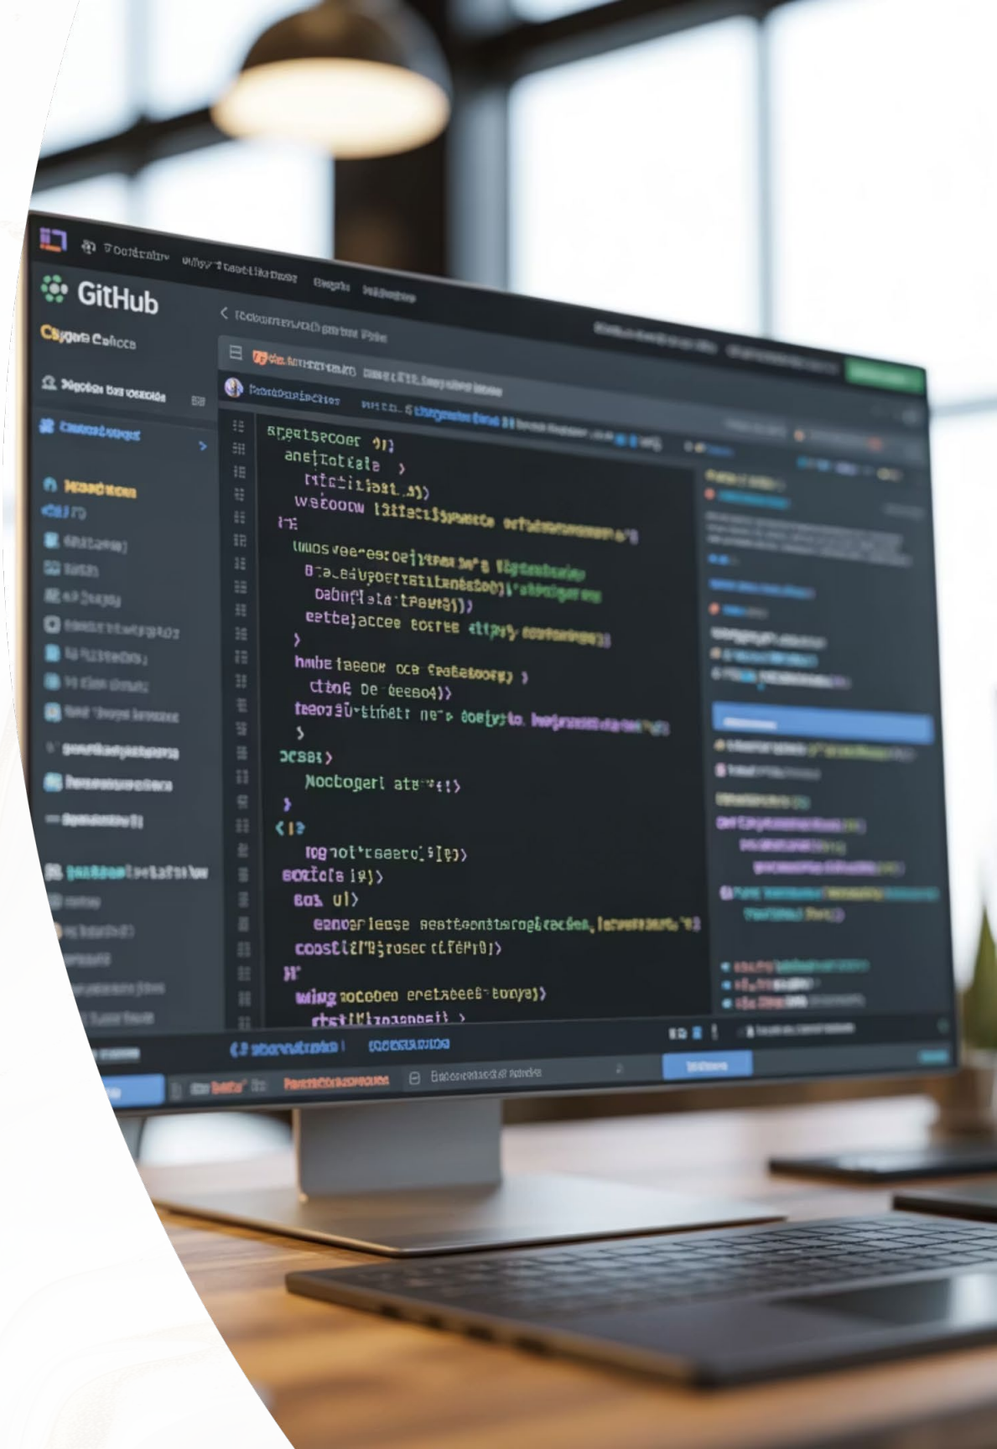

Características Clave de GitHub

Repositorios Remotos

Almacenamiento seguro en la nube de tu código con respaldo automático y acceso desde cualquier lugar.

Issues

Sistema de seguimiento de tareas, errores y mejoras que facilita la gestión organizada del proyecto.

Actions

Automatización de pruebas, despliegues y flujos de trabajo mediante integración continua.

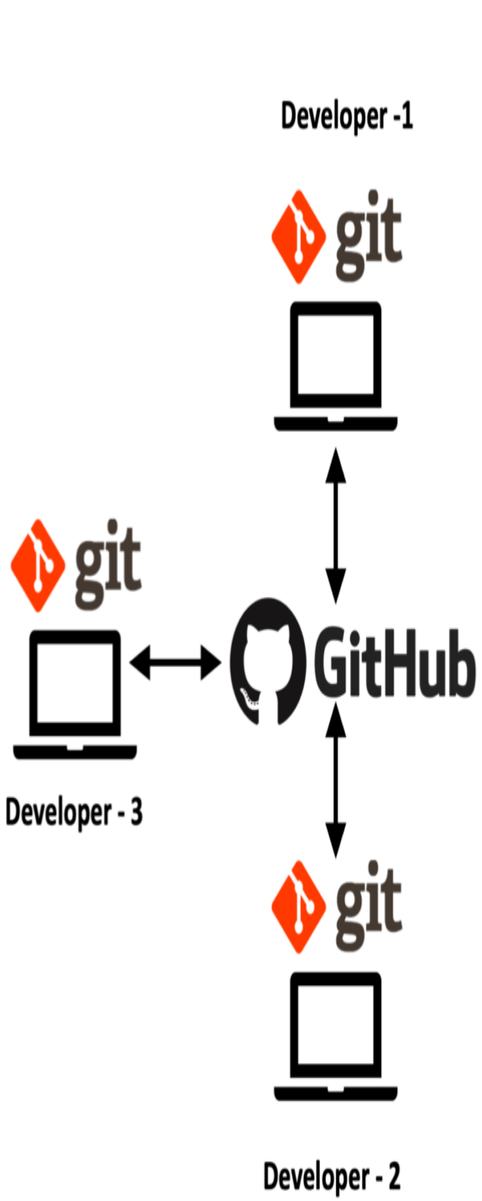

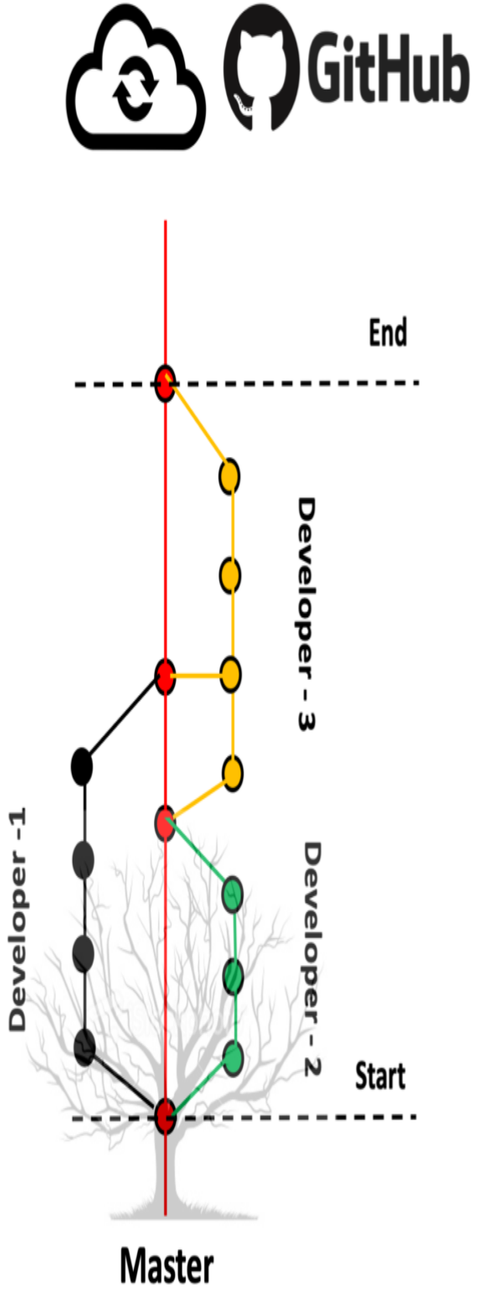

Características Clave de GitHub

Pull Requests

Propuesta de cambios que permite revisión de código antes de integrar modificaciones a la rama principal.

Colaboración

Múltiples usuarios pueden trabajar simultáneamente con control de permisos y flujos de aprobación.

Documentación

Wikis y archivos README para documentar el proyecto de forma accesible y profesional.

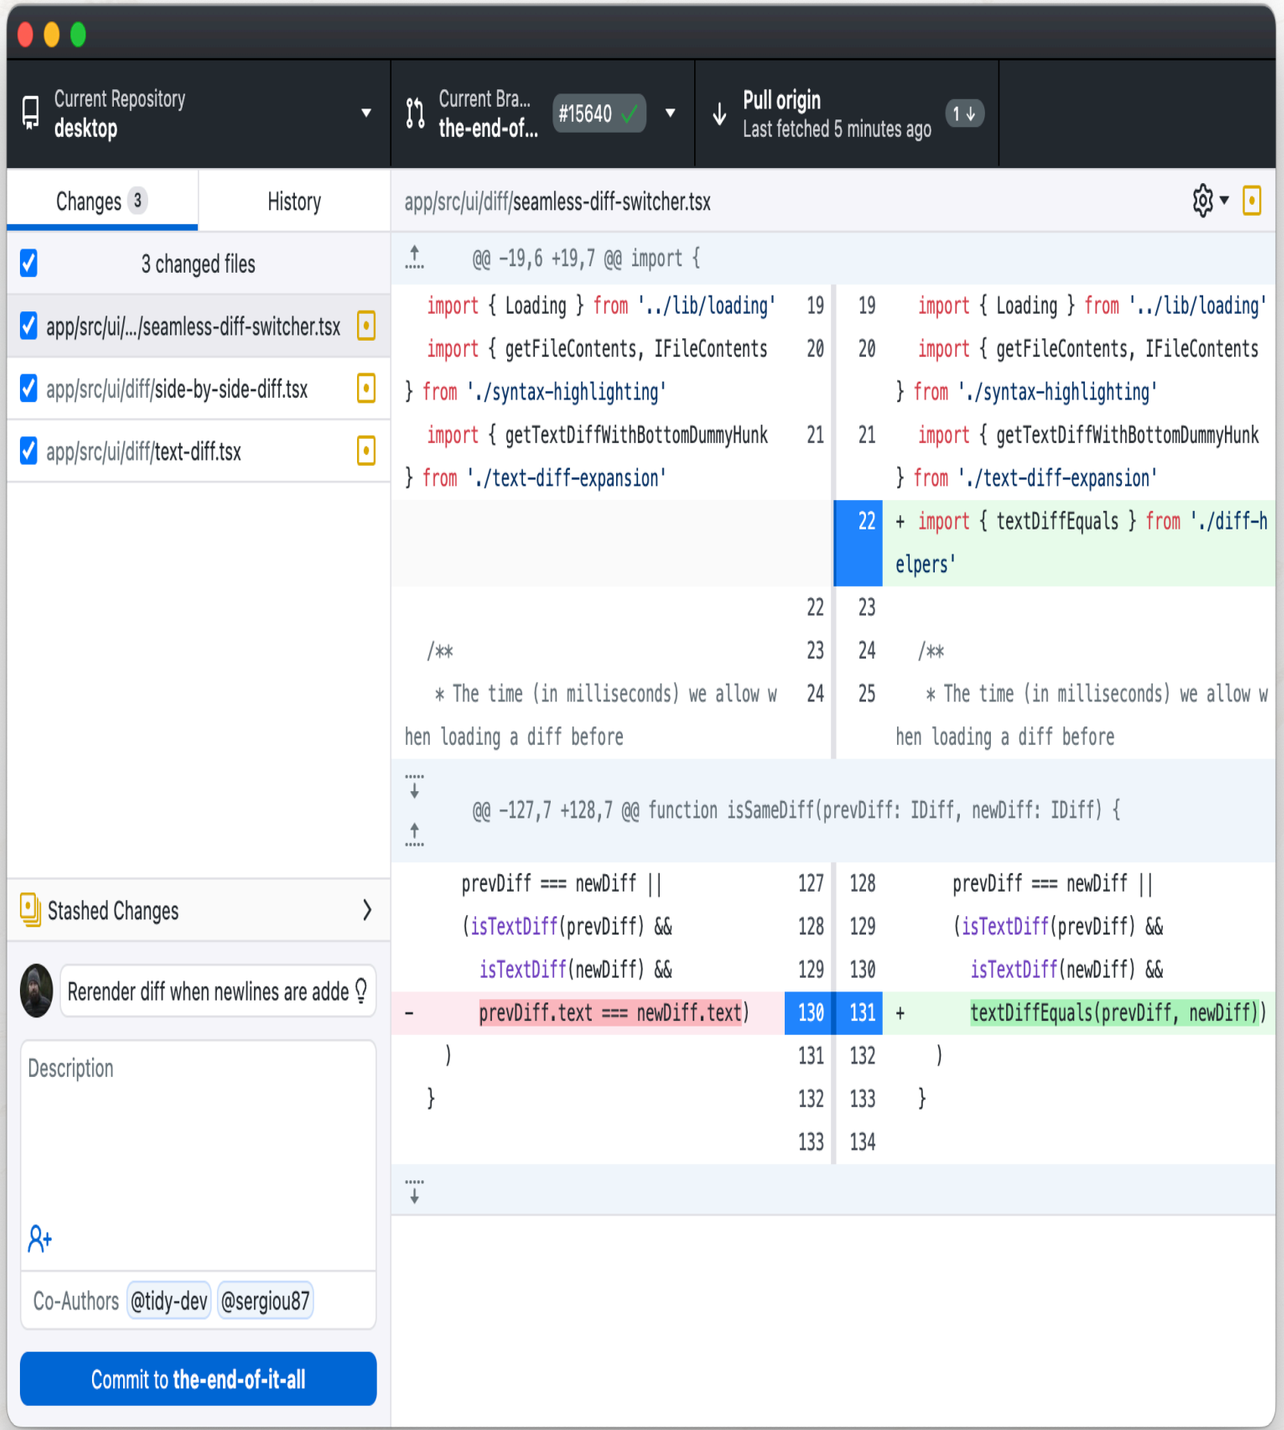

Flujo de Trabajo Colaborativo en GitHub

1

Fork del Repositorio

Creas una copia personal del proyecto en tu cuenta de GitHub para trabajar de forma independiente.

2

Clone Local

Descargas el repositorio a tu computadora con `git clone` para comenzar el desarrollo.

3

Crear Rama

Generas una nueva rama para tu característica o corrección con `git checkout -b feature-nueva`.

4

Desarrollo y Commits

Trabajas en los cambios y realizas commits regulares con mensajes descriptivos.

5

Push a GitHub

Subes tu rama al repositorio remoto con `git push origin feature-nueva`.

6

Pull Request

Creas una solicitud de integración donde el equipo revisa tu código antes de aprobarlo.

7

Revisión y Merge

Después de la aprobación, los cambios se integran a la rama principal del proyecto.

Python: El Lenguaje Versátil

Python se ha consolidado como el lenguaje preferido para ciencia de datos gracias a su sintaxis clara, su filosofía de legibilidad y su ecosistema extraordinariamente rico de bibliotecas especializadas.

Creado en 1991 por Guido van Rossum, Python es un lenguaje de propósito general que se destaca en ciencia de datos, desarrollo web, automatización, inteligencia artificial y muchas otras áreas.

Su comunidad activa y su vasta documentación lo hacen ideal tanto para principiantes como para expertos en el campo.

Ventajas de Python para Ciencia de Datos

1

Sintaxis Legible

Código que parece pseudocódigo, reduciendo la curva de aprendizaje y facilitando el mantenimiento. La filosofía "Beautiful is better than ugly" hace que el código sea auto-documentado.

2

Ecosistema Rico

Miles de bibliotecas especializadas para cada tarea imaginable en ciencia de datos, desde manipulación de datos hasta aprendizaje profundo y visualización avanzada.

3

Comunidad Activa

Millones de desarrolladores en todo el mundo comparten conocimiento, resuelven dudas y contribuyen con nuevas herramientas constantemente.

4

Versatilidad

No solo sirve para análisis de datos: puedes construir APIs, automatizar tareas, crear dashboards interactivos y desplegar modelos en producción.

5

Integración

Se conecta fácilmente con bases de datos, servicios web, otros lenguajes y herramientas empresariales, facilitando proyectos end-to-end.

6

Gratuito y Open Source

Sin costos de licencia y con código abierto que permite entender cómo funcionan las herramientas internamente.

Bibliotecas Esenciales de Python

Pandas

La herramienta fundamental para manipulación y análisis de datos estructurados. Ofrece DataFrames potentes para limpiar, transformar y analizar datos de manera eficiente.

NumPy

La base de la computación numérica en Python. Proporciona arrays multidimensionales y operaciones matemáticas de alto rendimiento.

Matplotlib

Biblioteca de visualización versátil para crear gráficos estáticos, animados e interactivos de calidad publicable.

Scikit-learn

La biblioteca líder para aprendizaje automático, con implementaciones de algoritmos de clasificación, regresión, clustering y más.

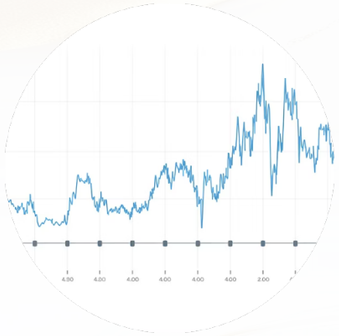

Seaborn

Visualización estadística de alto nivel construida sobre Matplotlib, perfecta para exploración visual de datos complejos.

Jupyter

Entorno de notebooks interactivos que combina código, visualizaciones y documentación en un mismo documento.

R: El Lenguaje de los Estadísticos

R es un lenguaje y entorno de programación diseñado específicamente para computación estadística y visualización gráfica. Creado en 1993 por Ross Ihaka y Robert Gentleman, R se ha convertido en la herramienta preferida en ámbitos académicos, de investigación y análisis estadístico avanzado.

Su sistema de paquetes CRAN (Comprehensive R Archive Network) contiene más de 19,000 paquetes especializados que cubren prácticamente cualquier método estadístico imaginable.

R brilla especialmente en análisis exploratorio de datos, modelado estadístico complejo y creación de visualizaciones de alta calidad para publicaciones científicas.